

Clase 15 Diagnóstico de regresión

Residuos

$$e_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_{p-1} X_{i(p-1)}) = Y_i - X_i^T \hat{\beta}$$

$$e = Y - X\hat{\beta}$$

Propiedades

- $E(e_i) = 0$
- $\text{Var}(e_i) = \sigma^2 [1 - X_i^T (X^T X)^{-1} X_i] = \sigma^2 (1 - h_{ii})$
- $\text{Cov}(e_i, e_j) = -\sigma^2 X_i^T (X^T X)^{-1} X_j = -\sigma^2 h_{ij}$
- Residuos NO son una muestra aleatoria de $N(0, \sigma^2)$
No son independientes

Residuos Studentizados

internamente

$$r_i = \frac{e_i}{\sqrt{\hat{\sigma}^2 (1 - h_{ii})}} \sim N(0, 1) \quad \text{para } i = 1, \dots, n$$

externamente

$$t_i = \frac{e_i}{\sqrt{\hat{\sigma}^2 (1 - h_{ii})}} \sim t_{n-p-1} \quad i = 1, \dots, n$$

$$\hat{\sigma}^2 = \frac{\hat{\sigma}^2}{n-p-1} (n-p-1)$$

CS Linealidad: Análisis gráfico
Test de Hipótesis

Test F de Fisher-Snedecor

- $H_0: \mu_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_{p-1} X_{i(p-1)}$
- Bajo H_0 , $F = \frac{MCFA}{MCEP} \sim F_{(k-p, n-k)}$
- a nivel de significancia α ,
rechazamos H_0 si $F > F_{(k-p, n-k; \alpha)}$

Clase 14 Anova / Inferencia

①

FV	SC	GL	MC	Test F
Regresión	$SCR = \sum_i^n (\hat{Y}_i - \bar{Y})^2$	$p-1$	$MCR = \frac{SCR}{p-1}$	$F = \frac{MCR}{MCE}$
Error	$SCE = \sum_i^n (Y_i - \hat{Y}_i)^2$	$n-p$	$MCE = \frac{SCE}{n-p}$	
Total	$SCT = \sum_i^n (Y_i - \bar{Y})^2$	$n-1$		

Test F de Fisher - Snedecor

$$H_0: \beta_1 = \beta_2 = \dots = 0$$

$$H_1: \text{algún } \beta \neq 0$$

- Bajo H_0 , $F = \frac{MCR}{MCE} \sim F_{(p-1, n-p)}$
- A nivel α , rechazamos H_0 si $F > F_{(p-1, n-p, \alpha)}$

$$R^2 \text{ corregido: } R_a^2 = 1 - \frac{n-1}{n-p} (1 - R^2)$$

el valor pes menor que eso,
por lo que rechazamos H_0 .
Si es signif.

$$Y_i \sim N(\mu_i, \sigma^2)$$

$$\mu_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_{p-1} X_{i(p-1)} = X_i^T \beta \quad i=1, \dots, n$$

estimar para X_h específico.

$$E(Y|X=x_h) = X_h^T \beta$$

$$\hat{\mu}_h = X_h^T \hat{\beta} \sim N[E(\hat{\mu}_h), \text{Var}(\hat{\mu}_h)]$$

donde $E(\hat{\mu}_h) = X_h^T \beta$ y

$$\begin{aligned} \text{Var}(\hat{\mu}_h) &= \text{Var}(X_h^T \hat{\beta}) = X_h^T \text{Var}(\hat{\beta}) X_h \\ &= \sigma^2 X_h^T (X^T X)^{-1} X_h \end{aligned}$$

$$\Rightarrow \mu_h \in \left(\hat{\mu}_h \pm t_{(n-p), \alpha/2} \sqrt{X_h^T (X^T X)^{-1} X_h} \right)$$

Clase B Regresión Lineal Múltiple

Estimación y propiedades

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_{p-1} X_{(p-1)i} + \epsilon_i$$

Condiciones Gauss-Markov

- 1) $E(\epsilon_i) = 0$ $i = 1, \dots, n$
- 2) $\text{Var}(\epsilon_i) = \sigma^2$ $i = 1, \dots, n$ (homocedasticidad)
- 3) $E(\epsilon_i \epsilon_j) = 0 \quad \forall i \neq j$ (observaciones incorrelacionadas)
- 4) $\epsilon_i \sim N(0, \sigma^2)$ $i = 1, \dots, n$ (Normalidad)
- 5) $X^T X$ no singular, en caso contrario, multicolinealidad

Notación Matricial

$$Y = X\beta + \epsilon, \quad \epsilon \sim N(0, \sigma^2 I)$$

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_m \end{pmatrix}$$

$$\beta_{p \times 1} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix}$$

$$\epsilon_{m \times 1} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_m \end{pmatrix}$$

$$X_{m \times p} = \begin{pmatrix} 1 & X_{11} & \dots & X_{1(p-1)} \\ 1 & X_{21} & \dots & X_{2(p-1)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{m1} & \dots & X_{m(p-1)} \end{pmatrix}$$

$$\text{donde } \text{rang}(X_{m \times p}) = p \leq m$$

Estimadores

②

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

$$\hat{\sigma}^2 = \frac{RSS(\hat{\beta})}{n} \text{ [Sesgado]} \rightarrow \hat{\sigma}^2 = \frac{RSS(\hat{\beta})}{n-p} \text{ [Ins sesgado]}$$

Distribución estimadores

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

$$\frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p}^2 \quad \text{Si } p=2 \Rightarrow \text{Simple}$$

$$\hat{\sigma}^2 \text{ indep. de } \hat{\beta}$$

Efecto interacción

- Los modelos de reg. con interacción (o efectos no aditivos) son casos especiales del modelo de reg. lineal.
- Efecto variables indep. en var. resp. no son aditivos.
- En estos casos, efecto de una var. indep. depende de los niveles de otras var. indep.

Regresión polinomial

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_{2i}^2 + \epsilon_i$$

Transformación de Variables

③

Var. indep. No se observa relación lineal
e.g. $\log(x)$, x^2 , \sqrt{x}

Var. Dependiente

- No se observa relación lineal
- Residuos no se distribuyen normalmente
- $\log(Y)$, Y^2 , \sqrt{Y}
- Box-Cox, Atkinson, Johnson

Box-Cox: Encuentra valor apropiado para obtener normalidad de residuos.

$$Y_i^*(\lambda) = \begin{cases} \frac{Y_i^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \log(Y_i) & \lambda = 0 \end{cases}$$

- 1) Coef. correlación basado en Normal
- 2) Test normalidad Shapiro - Wilk
- 3) Máxima Verosimilitud (Normal)

Buscamos el λ que maximice log-likelihood. (Verosimilitud)

En los test, H_0 es parámetro = 0, con $\alpha = 5\%$.

Si valor p es menor a 5% , \Rightarrow es significativo y rechazamos H_0 .

Ej. práctico: buscar λ que optimiza Box-Cox.

1. Ajusta modelo y verifica si residuos son normales.